

第3章 球和箱子模型 — 核心知识点与考点指南

面向 408 计算机考研及哈工大研究生高级算法课程（含经典分布式与散列算法分析）

考点重要度图例：★ 核心重难点（常考推导、必背结论，大题高频）

▲ 重点掌握（常用于性质证明或经典应用分析）

■ 理解即可（概率基础复习或自学了解内容）

3.1 与硬币投掷相关的三种基本分布

知识点 1：伯努利试验（Bernoulli Trial）

■ 理解即可

单次随机试验只有两种可能结果（成功与失败）。设成功的概率为 p ，失败的概率为 $1-p$ 。其期望 $E[X] = p$ ，方差 $Var[X] = p(1-p)$ 。

知识点 2：几何分布（Geometric Distribution）

▲ 重点掌握

在独立重复的伯努利试验中，试验直到首次成功所需的投掷次数 X 服从几何分布。其概率质量函数为 $Pr[X=n] = (1-p)^{n-1}p$ 。其数学期望 $E[X] = 1/p$ 。在赠券收集问题中有着极高频的应用。

知识点 3：二项分布（Binomial Distribution）

▲ 重点掌握

n 次独立重复的伯努利试验中，成功总次数 X 服从二项分布。其期望为 $E[X] = np$ ，方差为 $Var[X] = np(1-p)$ 。常作为球箱模型中某个特定箱子中球个数的精确分布。

3.2 桶排序及其时间复杂度分析

知识点 4：桶排序（Bucket Sort）的基本思想

■ 理解即可

假设输入数据均匀独立地分布在区间 $[0, 1)$ 内。将该区间均匀划分为 n 个子区间（桶）。将 n 个输入数分配到对应的桶中，对每个桶内的元素利用插入排序，最后依次拼接各个桶的输出。

知识点 5：桶排序线性期望时间复杂度的严格证明 ★ 核心重难点

设每个桶内元素个数为 n_i ，插入排序代价为 $O(n_i^2)$ 。总期望时间为 $E[T(n)] = O(n) + \sum O(E[n_i^2])$ 。由于每个数落入任意桶的概率为 $p = 1/n$ ，因此 n_i 服从二项分布 $B(n, 1/n)$ 。利用期望性质：

$$E[n_i^2] = \text{Var}[n_i] + (E[n_i])^2 = n(1/n)(1 - 1/n) + 1^2 = 2 - 1/n < 2$$

代入得 $E[T(n)] = O(n) + n \cdot O(1) = O(n)$ 。这是高级算法考试中概率分析大题的经典模板。

3.3 跳表（Skip List）及其操作复杂度分析

知识点 6：跳表的数据结构定义 ▲ 重点掌握

跳表是一种高效的动态搜索结构，通过在链表之上构建多级稀疏索引来实现类似于二分查找的效率。其高度是随机决定的：对每个新插入的节点，通过反复投掷硬币（成功率为 $p = 1/2$ ），直到出现背面为止，正面连续出现的次数决定该节点的索引层数。

知识点 7：跳表空间复杂度的期望分析 ▲ 重点掌握

第 i 层节点保留在第 $i+1$ 层的概率为 $1/2$ 。因此第 i 层期望节点数为 $n / 2^{i-1}$ 。总空间期望为 $\sum n / 2^{i-1} = 2n = O(n)$ 。

知识点 8：跳表查找复杂度的逆向分析法（Backward Analysis） ★ 核心重难点

从目标节点逆向看查找路径：如果当前处于某层的最左端节点，则必然是从下一层爬升上来的（概率为 $1/2$ ）；否则必然是从左侧兄弟节点水平向右移动而来的（概率为 $1/2$ ）。这相当于一个反向的伯努利试验：路径步数等于“直到成功爬升到最上层顶端”所需的试验次数。由此，期望水平移动次数和爬升次数之和均被限制在高度与线性的乘积内，平均查找时间复杂度严格为 $O(\log n)$ 。

3.4 球和箱子模型基础理论与经典悖论

知识点 9：球箱模型核心形式定义 ▲ 重点掌握

将 m 个球独立、均匀地随机投掷到 n 个箱子中。每个球落入任意一个特定箱子的概率均为 $1/n$ 。该模型是负载均衡、多核调度、哈希冲突和分布式缓存分析的数学根基。

知识点 10：生日悖论（Birthday Paradox）的数学实质 ★ 核心重难点

当球数 m 达到多大时，至少有两个球落入同一个箱子的概率大于 $1/2$ ？不发生冲突的概率为 $Pr[\text{无冲突}] = \prod_{i=1}^{m-1} (1 - i/n)$ 。利用泰勒展开近似 $1 - x \leq e^{-x}$ ，得到：

$$Pr[\text{无冲突}] \leq \prod e^{-i/n} = e^{-m(m-1)/2n}$$

令该式等于 $1/2$ ，解得 $m \approx \sqrt{(2 \ln 2 \cdot n)} = O(\sqrt{n})$ 。考试核心结论：在一年的 $n = 365$ 天中，只需 $m = 23$ 人即可让至少两人同一天生日的概率超 50%。该结论在密码学哈希碰撞测试和散列冲突分析中极端重要。

3.5 赠券收集问题（Coupon Collector's Problem）

知识点 11：赠券收集问题定义与随机变量分解 ★ 核心重难点

目标是收集满 n 种不同的赠券，每次随机获得一种。问集齐所有赠券所需的期望购买次数 X 是多少？将总次数分解为 $X = \sum_{i=0}^{n-1} X_i$ ，其中 X_i 表示在已拥有 i 种独特赠券后，到获得第 $i+1$ 种新赠券所需的购买次数。

知识点 12：集齐赠券期望时间的严格推导与调和级数 ★ 核心重难点

在已拥有 i 种不同的赠券时，下一次买到新赠券的概率为 $p_i = (n - i) / n$ 。因此，随机变量 X_i 服从几何分布，其期望为 $E[X_i] = 1 / p_i = n / (n - i)$ 。利用期望的线性性质：

$$E[X] = \sum E[X_i] = \sum n / (n - i) = n (1/n + 1/(n-1) + \dots + 1/2 + 1) = n \cdot H_n$$

其中 H_n 为调和级数，近似为 $\ln n + \gamma$ 。因此集齐期望时间为 $E[X] = n \ln n + O(n)$ 。

知识点 13：赠券收集问题的方差约束及尾概率 ▲ 重点掌握

由于各个几何分布变量 X_i 之间是相互独立的，方差满足可加性： $Var[X] = \sum Var[X_i] = \sum (1 - p_i) / p_i^2 \leq \sum n^2 / (n-i)^2 \leq \pi^2 n^2 / 6$ 。方差为 $O(n^2)$ 说明其实际分布高度集中在期望值附近，极少发生巨大偏离。

3.6 最大负载与并行资源分配

知识点 14：经典最大负载（Maximum Load）结论 ★ 核心重难点

当将 $m = n$ 个球随机投到 n 个箱子中时，球数最多的那个箱子（即最大负载）在大概率（With High Probability）下的渐进上界为 $O(\log n / \log \log n)$ 。这表明完全随机的资源分配会产生一定的局部不均衡。

知识点 15：最大负载结论的严格泊松近似证明步骤 ★ 核心重难点

任意一个特定箱子中恰好落入 k 个球的精确概率为二项分布： $\Pr[X_i=k] = C_n^k (1/n)^k (1 - 1/n)^{n-k}$ 。当 n 很大时，可以用参数 $\lambda = np = 1$ 的泊松分布近似： $\Pr[X_i=k] \approx e^{-1} / k!$ 。利用斯特林公式缩放阶乘 $k! \geq (k/e)^k$ ，得到 $\Pr[X_i \geq k] \leq (e/k)^k$ 。令联合界条件成立，使得所有箱子均不超标： $n \cdot (e/k)^k \leq 1/n$ ，取对数解得 $k = O(\log n / \log \log n)$ 。

知识点 16：两位选择的力量（The Power of Two Choices）★ 核心重难点

如果在投掷每个球时，不是随机选择一个箱子，而是随机选择两个箱子，并比较它们当前的负载，将球放入那个较空的箱子中。那么最大负载将戏剧性地从 $O(\log n / \log \log n)$ 暴跌至 $O(\log \log n)$ 。这种机制被称为贪婪两选择分配，是分布式负载均衡（如 nginx 调度、哈希表设计）中极其核心的设计思想。

3.7 通用散列函数族（Universal Hashing）

知识点 17：确定性散列的致命缺陷 ■ 理解即可

对于任何固定的常规散列函数，都存在一组特定的极端恶意输入集合（Bad Input），使得所有键值全部映射到同一个槽位中，从而导致哈希表的检索效率直接从理想的 $O(1)$ 退化至最坏情况下的 $O(n)$ 。

知识点 18：通用散列函数族（Universal Hashing）的数学定义 ★ 核心重难点

设 $\mathcal{H}$ 是从大宇宙集合 U 映射到有限槽集合 $\{0, 1, \dots, n-1\}$ 的一个散列函数集合。如果对于任意两个不同的键值 $x, y \in U (x \neq y)$ ，从 $\mathcal{H}$ 中随机挑选出一个散列函数 h ，它们发生碰撞的概率满足：

$$\Pr_{h \in \mathcal{H}}[h(x) = h(y)] \leq 1/n$$

则称该函数族 $\mathcal{H}$ 是通用的（Universal）。它通过在运行时动态随机选择散列函数，阻断了恶意攻击者构造最坏实例的可能性。

知识点 19：通用散列函数族的平均检索代价证明 ★ 核心重难点

在一个包含 n 个槽位的哈希表中，插入 m 个元素，若使用从通用散列族中随机选出的函数 h 。对任意特定元素 x ，定义指示随机变量 I_y 表示 y 是否与 x 冲突。发生冲突的期望元素总数为：

$$E[\sum_{y \neq x} I_y] = \sum_{y \neq x} E[I_y] = \sum_{y \neq x} \Pr[h(x)=h(y)] \leq m \cdot (1/n) = m/n$$

因此，任意元素的平均链表检索长度仅为 $1 + m/n$ 。若装载因子 $\alpha = m/n = O(1)$ ，则期望检索复杂度完全稳定在 $O(1)$ 。

知识点 20：一个经典的通用散列函数族构造实例 ▲ 重点掌握

选定一个足够大的质数 p （使得所有键值均小于 p ）。定义参数化函数族： $h_{a,b}(x) = ((ax + b) \bmod p) \bmod n$ 。其中 $a \in \{1, 2, \dots, p-1\}$, $b \in \{0, 1, \dots, p-1\}$ 。可以证明，由此构成的函数族包含 $p(p-1)$ 个函数，且严格满足通用散列的碰撞概率界限。

3.8 布隆过滤器（Bloom Filter）的数学分析

知识点 21：布隆过滤器的数据结构与基本操作 ▲ 重点掌握

布隆过滤器用于极其高效地测试一个元素是否属于一个集合。它由一个长度为 n 位的位数组（Bit Array）以及 k 个独立的通用散列函数组成。插入元素时，用 k 个散列函数分别计算该元素的哈希值，并将位数组中对应 k 个位置的比特全置为 1。

知识点 22：布隆过滤器的核心无假阴性特征 ▲ 重点掌握

布隆过滤器具有**绝对无假阴性（No False Negatives）**的特征：如果检索一个元素时，其对应的 k 个位中有任何一位为 0，则该元素**必定绝对没有**被插入过该集合。但它存在**假阳性（False Positives）**的可能，即由于哈希冲突，一个未插入过的元素对应的 k 个位也可能刚好全部被其他元素染成了 1。

知识点 23：布隆过滤器假阳性概率的完整数学推导 ★ 核心重难点

设位数组大小为 n ，已插入元素个数为 m ，散列函数个数为 k 。1. 投掷一个球（进行一次散列映射），某个特定位仍保持为 0 的概率为 $1 - 1/n$ 。2. 插入所有 m 个元素（共产生 km 个球）后，该特定位仍旧为 0 的概率为 $p = (1 - 1/n)^{km} \approx e^{-km/n}$ 。3. 从而，该位被置为 1 的概率为 $1 - p = 1 - e^{-km/n}$ 。4. 测试一个新元素时，其 k 个散列位全刚好为 1（发生假阳性）的概率为：

$$Pr[\text{假阳性}] = (1 - p)^k \approx (1 - e^{-km/n})^k$$

知识点 24：最优散列函数个数 k 的求导与优化选择 ★ 核心重难点

为了在给定的集合大小 m 和位宽 n 下最小化假阳性概率，需要对函数 $g(k) = \ln(Pr[\text{假阳性}]) = k \cdot \ln(1 - e^{-km/n})$ 求一阶导数，并令其等于 0。解得当 $k = \ln 2 \cdot (n/m) \approx 0.693 \cdot (n/m)$ 时，布隆过滤器取得全局最低的假阳性率。此时，位数组中有一半的位置被置为了 1（信息熵达到最大）。代入可得此时的最佳假阳性概率为：

$$Pr[\text{最佳假阳性}] = (1/2)^k \approx (0.6185)^{n/m}$$

知识点 25：布隆过滤器的现代工业应用场景 ■ 理解即可

广泛用于避免昂贵的磁盘/网络 I/O 检索。例如：垃圾邮件地址库过滤、网页爬虫 URL 去重、分布式数据库（如 HBase、Cassandra、BigTable）在读取 SSTable 时的前置判定以防止无效的缓存未命中穿透。