

高级算法设计与分析 —— 第5章：鞅 (Martingale)

复习精简知识点与全考点梳理手册

1. 概率论基础补充与核心概念

基础 1.1 条件概率核心定义

设随机事件 E_1 在事件 E_2 发生的条件下的条件概率定义为：

$$Pr[E_1 | E_2] = Pr[E_1 \wedge E_2] / Pr[E_2]$$

若两事件独立，则有 $Pr[E_1 | E_2] = Pr[E_1]$ 。

高频 1.2 条件期望及其随机变量性质

随机变量 Y 关于 X 的条件期望定义为：

$$E[Y | X] = \sum_y y \cdot Pr[Y = y | X]$$

注意： $E[Y | X]$ 是关于随机变量 X 的函数，因此其自身也是一个随机变量。一旦给定具体观测值 $X = x$ ，则 $E[Y | X = x]$ 退化为一个确定的实数值。

重难点 1.3 条件期望的三大基本性质（核心计算工具）

考试中进行鞅证明与推导的核心性质包括：

- **性质1（全期望公式）：** $E[Y] = E[E[Y | X]]$ 。即所有样本均值等于各局部均值的均值。
- **性质2（嵌套条件期望）：** $E[Y | Z] = E[E[Y | X, Z] | Z]$ 。
- **性质3（带出已知项）：** $E[f(X)g(X, Y) | X] = f(X) \cdot E[g(X, Y) | X]$ 。一旦给定 X ，所有纯 X 的函数均可视为常数提出来。

2. 鞅的定义与经典判别模型

必考 2.1 鞅 (Martingale) 的标准定义

对于一个随机变量序列 $X_0, X_1, X_2, \dots$ ，如果对于任意的 $i \geq 1$ ，均满足以下条件：

$$E[X_i | X_0, X_1, \dots, X_{i-1}] = X_{i-1}$$

则称该序列是一个鞅。等价变换形式为： $E[X_i - X_{i-1} | X_0, \dots, X_{i-1}] = 0$ ，意味着每一步的“净收益”期望为0。

高频 2.2 经典鞅模型 1：公平赌局 (Fair Game)

初始赌资 $X_0 = b$ ，每轮以 $1/2$ 的概率赢 a ，以 $1/2$ 的概率输 a ，且每局独立。由于：

$$E[X_i | X_{i-1}] = (X_{i-1} + a) \cdot (1/2) + (X_{i-1} - a) \cdot (1/2) = X_{i-1}$$

故其赌资序列是一个标准的鞅。同理，均匀硬币投掷中，“正面向上次数”与“背面向上次数”之差的序列也是一个鞅。

高频 2.3 经典鞅模型 2：波利亚壶模型 (Pólya Urn Model)

壶中初始有 b 个蓝球， w 个白球。每次随机抓出一个球，放回时顺便多放入 c 个同色球。设 X_i 为第 i 次操作后蓝球所占的比例。经推导证明可得：

$$E[X_i | X_0, \dots, X_{i-1}] = X_{i-1}$$

结论：波利亚壶模型中，蓝球比例序列 $\{X_i\}$ 构成一个鞅。

基础 2.4 基础恒等性质

若随机变量序列 $\{Y_i\}$ 是关于序列 $\{X_i\}$ 的鞅，则它们的数学期望恒等：

$$E[Y_i] = E[Y_{i-1}] = \dots = E[Y_0]$$

该性质是利用鞅求解期望的核心桥梁。

3. 鞅的一般形式与重要构造法

高频 3.1 零均值随机变量和的鞅构造

若 $X_1, X_2, \dots$ 是独立的随机变量，且均满足 $E[X_i] = 0$ 。定义部分和序列 $Y_i = X_1 + X_2 + \dots + X_i$ ，则 $\{Y_i\}$ 是一个鞅。

重难点 3.2 零均值方差和的平方鞅构造

设 $X_1, X_2, \dots$ 是独立且均值为 0、方差为 σ^2 的随机变量序列。定义：

$$Y_i = (\sum_{k=1}^i X_k)^2 - i\sigma^2$$

经利用条件期望性质展开证明， $E[Y_i | X_1, \dots, X_{i-1}] = Y_{i-1}$ 。结论：均值为 0 的随机变量和的平方减去累计方差，构成一个鞅。

必考 3.3 杜布鞅 (Doob Martingale) 序列 (极为重要)

设 $f(X_1, X_2, \dots, X_n)$ 是任意随机变量序列的函数，定义序列：

$$Y_i = E[f(X_1, X_2, \dots, X_n) | X_1, X_2, \dots, X_i], \quad \forall i = 0, 1, \dots, n$$

其中 $Y_0 = E[f(X_1, \dots, X_n)]$ (没有任何观测信息时的期望)， $Y_n = f(X_1, \dots, X_n)$ (完全暴露时的具体取值)。

结论：任何 Doob 序列必是一个鞅。它刻画了随着信息 $X_1, \dots, X_i$ 的逐步暴露，人们对最终函数值估计的精细化过程。

4. 停时定理与瓦尔德方程 (经典应用计算点)

高频 4.1 停时 (Stopping Time) 的定义

若一个随机变量 T 的取值仅依赖于截止到当前时刻的历史数据 $Y_0, Y_1, \dots, Y_T$ 的具体取值，而不需要预知未来的信息，则称 T 是一个停时。

必考 4.2 鞅的停时定理 (Martingale Stopping Theorem)

设 $\{Y_i\}$ 是关于 $\{X_i\}$ 的鞅, T 是其一个有限停时。若满足停时定理边界条件, 则有:

$$E[Y_T] = E[Y_0]$$

常考场景: 公平赌局止损/止盈点概率求解、选举定理证明 (始终领先的概率为 $(a-b)/(a+b)$)。

必考 4.3 瓦尔德方程 (Wald's Equation)

设 $X_1, X_2, \dots$ 是独立同分布的随机变量, T 是关于该序列的一个停时, 且 $E[T]$ 和 $E[X]$ 均有限。则满足:

$$E[\sum_{i=1}^T X_i] = E[T] \cdot E[X]$$

常考场景应用:

- 骰子双轮赌局: 第一轮掷出点数 X 确定第二轮掷骰子次数, 求总收益期望: $E[Z] = E[X] \cdot E[Y] = (7/2) \cdot (7/2) = 49/4$ 。
- Las Vegas 算法期望运行时间: 期望运行时间分析, $E[\text{运行总时间}] = E[\text{循环轮数}] \times T(n) = T(n)/p(n)$ 。
- 共享总线服务器通信: 多台机器冲突退避, 结合赠券收集模型与瓦尔德方程求解总延迟。

5. 鞅尾不等式与集中性集中度分析 (论述/证明大题核心)

必考 5.1 Azuma 不等式 (阿祖玛不等式)

设 $X_0, X_1, X_2, \dots$ 是一个鞅序列。如果对于任意的 $k \geq 1$, 均满足每步有界跳跃条件 $|X_k - X_{k-1}| \leq c_k$, 则对于任意的 $t > 0$:

$$\Pr[|X_n - X_0| \geq t] \leq 2 \cdot \exp(-t^2 / (2 \sum_{k=1}^n c_k^2))$$

推论 (等步长版): 若恒有 $|X_k - X_{k-1}| \leq c$, 则:

$$\Pr[|X_n - X_0| \geq c \cdot t \cdot \sqrt{n}] \leq 2e^{-t^2/2}$$

该公式用于有力地证明某些随机变量随规模增大, 极高概率集中在均值附近。

高频 5.2 集中性的一般证明步骤（考场大题套路）

要把随机变量 $f(X_1, \dots, X_n)$ 用 Azuma 限制集中性，套路为：

1. 构造关于该函数的 **Doob 鞅序列**（即边暴露鞅或点暴露鞅）。
2. 证明或说明每暴露一个随机信息项，函数的最大变化幅度有界，即 $|Y_k - Y_{k-1}| \leq c_k$ 。
3. 直接套用 Azuma 不等式公式，得出偏离期望值的概率上限。

6. 鞅三大经典案例深度剖析

高频 6.1 模式匹配问题（Pattern Matching）

在大小为 s 的字符集上随机生成长度为 n 的串，求固定模式串 B （长度 k ）的出现频率。

- 期望频次： $E[F] = (n - k + 1) \cdot (1/s)^k$ 。
- 应用 **Doob 鞅**（暴露每个位置的字符），每步最大跳跃限制为 k 。
- **尾部界**： $\Pr[|F - E[F]| \geq \epsilon] \leq 2 \cdot \exp(-\epsilon^2 / (2nk^2))$ 。说明模式串频率极度集中。

高频 6.2 球与箱子模型中的空箱子数

将 m 个球随机投入 n 个箱子中，设 X 为最终空箱子个数。

- 期望值： $E[X] = n \cdot (1 - 1/n)^m$ 。
- 构造球暴露鞅： Z_i 表示已知前 i 个球落入情况时空箱数的条件期望。
- 因为多投一个球，至多导致空箱数多减少 1 或不减，因而满足有界步长： $|Z_{i+1} - Z_i| \leq 1$ 。
- **集中度**： $\Pr[|X - E[X]| \geq \epsilon] \leq 2 \cdot \exp(-\epsilon^2 / (2m))$ 。

必考 6.3 随机图的色数集中性（边暴露鞅模型）

针对随机图模型 $G(n, p)$ ，顶点数固定为 n ，边数为 $n(n-1)/2$ 条。求真着色所需的最少颜色数（色数） $\chi(G)$ 。

- **边暴露鞅（Edge Exposure Martingale）**：将所有可能存在的边依次编号， $Y_i = E[\chi(G) | X_1, \dots, X_i]$ 。
- 由于任意增加一条边，图的色数最多增加 1（即 $\chi(G_{i+1}) \leq \chi(G_i) + 1$ ），满足有界跳跃： $|Y_{i+1} - Y_i| \leq 1$ 。
- **尾部约束结论**：边总数为 $m = n(n-1)/2$ ，带入可得色数高度集中于其数学期望附近。