

高级算法设计与分析 —— 第6章：随机抽样与随机舍入

复习精简知识点与全考点梳理手册 (ch6.pdf)

1. 随机游走与 SAT 问题求解

高频 1.1 2-SAT 问题的随机赋值算法 (Schöning 算法基础)

针对 2-SAT 问题，基础随机游走赋值算法流程：

- 初始时，随机选择一个赋值（每个变量以 $1/2$ 概率置为真/假）。
- 在最多 $2n^2$ 步的循环中：如果当前赋值已满足所有子句，则成功退出；否则，随机选择一个未被满足的子句，并在这个子句中随机挑选一个文字将其取值翻转 (Flip)。

必考 1.2 2-SAT 成功概率与一维随机游走分析

设当前赋值与真值满足赋值（若存在）相比，有 i 个变量不同：

- 翻转未满足子句中的一个文字，因为至少有一个文字在真值赋值中取相反值，故以至少 $1/2$ 的概率使错误的变量数减少 1（即从 i 变成 $i-1$ ）。
- 至多以 $1/2$ 的概率使错误变量数加 1（即从 i 变成 $i+1$ ）。
- 该过程完美映射为一维随机游走模型（带有反射壁 0 和吸收壁 n ）。
- 考试核心结论：2-SAT 算法在 $2n^2$ 步内找到满足解的期望步数是 $O(n^2)$ ，利用马尔可夫不等式可证其单次成功概率大于常数，通过外层重复可达极高概率成功。

重难点 1.3 3-SAT 问题的随机算法瓶颈

对于 3-SAT，选出的未满足子句有 3 个文字。翻转一个文字使其更接近真值赋值的概率变为至少 $1/3$ ，而远离的概率变为至多 $2/3$ 。

由于向右（远离目标）的趋势大于向左，这变成了带有负偏向 (Negative Bias) 的随机游走，导致期望运行时间变为指数级 $O((3/2)^n)$ 。Schöning 算法通过将步数限制在 $3n$ 步并不断重新随机初始化，成功将复杂度降低至 $O((4/3)^n)$ 。

2. 马尔可夫链与图上的随机游走

高频 2.1 马尔可夫链 (Markov Chain) 基本性质

- 马尔可夫性 (无记忆性) : 下一步的状态概率只与当前状态有关, 与过去的历史无关 : $\Pr[X_{t+1} = j \mid X_t = i, \dots, X_0 = i_0] = \Pr[X_{t+1} = j \mid X_t = i] = P_{ij}$ 。
- 平稳分布 (Stationary Distribution) : 满足 $\pi P = \pi$ 且 $\sum \pi_i = 1$ 的概率向量 π 。

必考 2.2 无向图随机游走的平稳分布

在连接图 $G=(V,E)$ 上, 顶点 v 的度数为 $d(v)$ 。图上随机游走每步以 $1/d(v)$ 的概率移向其任一邻居。

考试必考核心公式 : 其唯一的平稳分布 π_v 正比于顶点的度数 :

$$\pi_v = d(v) / (2|E|)$$

必考 2.3 访问时间 (Hit Time) 与通勤时间 (Commute Time) 定理

- 访问时间 h_{uv} : 从顶点 u 出发首次到达顶点 v 的期望步数。
- 通勤时间 C_{uv} : 从 u 出发到达 v 再返回 u 的期望步数, 满足 $C_{uv} = h_{uv} + h_{vu}$ 。
- 核心定理 : 若 $(u,v) \in E$ 是图中的一条边, 则 :

$$C_{uv} = h_{uv} + h_{vu} \leq 2|E|$$

高频 2.4 图的覆盖时间 (Cover Time)

覆盖时间 $C(G)$ 是指从某个顶点出发, 遍历图中所有顶点所需的期望步数。

通式结论 : 对于任意拥有 n 个顶点和 m 条边的连通图, 其覆盖时间上限为 :

$$C(G) \leq 2m(n-1) = O(n \cdot m)$$

例如 : 在线性图 (Line Graph) 中为 $O(n^2)$, 在最坏情况 (如棒棒糖图 Lollipop Graph) 下可达 $\Theta(n^3)$ 。

必考 2.5 空间复杂度为 $O(1)$ 的图连通性算法 (USTCON)

利用随机游走可以在只用对数级别空间 $O(\log n)$ 内存（仅需维护当前所在的顶点指针和计数器）的前提下，判定无向图中的两点 s 和 t 是否连通：

方法：从 s 出发随机游走 $2n^3$ 步。如果期间到达了 t ，则连通；否则判为不连通。其错误概率（由于覆盖时间限制）通过马尔可夫不等式控制在 $1/2$ 以下。

3. 随机抽样与蒙特卡罗 (Monte Carlo) 方法

基础 3.1 随机抽样核心概念

通过对部分样本的采集来估计总体的特征（如均值、比例）。通常通过构造指示随机变量，结合 **Chernoff 尾部不等式** 来界定样本数 N 与精度 ϵ 、置信度 δ 之间的关系。

高频 3.2 DNF 计数问题的 FPRAS 算法

对于 DNF（析取范式）公式，精确计数其满足赋值的数量是 #P-complete 问题。

Karp-Luby 算法思想（重要考点）：无法在全集 $\{0,1\}^n$ 中直接盲抽（因为可能合法解极稀疏）。改为定义集合 $U = \{(i, a) \mid a \text{ 满足子句 } C_i\}$ ，其大小 $|U| = \sum 2^{n-|C_i|}$ 可轻易精确计算。令 $S = \{(i, a) \in U \mid a \text{ 不满足任何 } j < i \text{ 的子句 } C_j\}$ 。显然 $|S|$ 正好等于 DNF 满足解数。由于 $|U|/|S| \leq m$ （ m 为子句数），在 U 空间中抽样能确保高效。样本数选择 $N = O(m/\epsilon^2 \cdot \log(1/\delta))$ 时构成 **FPRAS**（完全多项式随机近似方案）。

4. 随机舍入 (Randomized Rounding) 技术

必考 4.1 随机舍入的核心思想

面对整数线性规划 (ILP) 这一 NP-hard 问题：

1. 将其**松弛 (Relax)** 为普通的线性规划 (LP)，在多项式时间内解出分数解 $x_i^* \in [0, 1]$ 。
2. **舍入阶段 (Rounding)**：将分数解 x_i^* 视作概率，以 $\Pr[x_i = 1] = x_i^*$ 的概率独立地将该变量强行舍入为 1，以 $1 - x_i^*$ 的概率舍入为 0。

必考 4.2 MAX-SAT (最大满足问题) 的随机舍入与近似比分析

对于 MAX-SAT 问题, 设计 LP 松弛: 最大化 $\sum w_j y_j$, 满足对每个子句有 $\sum_{i \in C_j^+} x_i + \sum_{i \in C_j^-} (1 - x_i) \geq y_j$ 。解出分数解后, 按概率 x_i^* 随机舍入。

核心引理证明与代数不等式应用:

对于包含 k 个文字的子句 C_j , 该子句被满足的概率满足:

$$\Pr[C_j \text{ 被满足}] \geq [1 - (1 - 1/k)^k] \cdot y_j^*$$

当 $k=1$ 时, 比值为 1; 当 $k \rightarrow \infty$ 时, 该系数趋近于 $1 - 1/e \approx 0.632$ 。

结论: 纯随机舍入算法是一个 $(1 - 1/e)$ -近似算法 (即近似比约为 0.632)。

重难点 4.3 混合随机算法 (加权平均近似) 与 3/4-近似解

- 纯随机赋值算法: 对每个子句满足概率为 $1 - (1/2)^k$ 。对短子句效果差 ($k=1$ 时为 0.5), 对长子句效果极好。
- 纯随机舍入算法: 满足概率为 $1 - (1 - 1/k)^k$ 。对短子句效果极好 ($k=1$ 时为 1), 对长子句效果差。
- 混合策略: 考场常考**混合算法证明题**。以 $1/2$ 概率运行纯随机赋值, 以 $1/2$ 概率运行 LP 随机舍入。两者的期望合并分析:

$$\text{解的期望值} \geq \sum w_j \cdot [(1 - (1/2)^k) + (1 - (1 - 1/k)^k)] / 2 \cdot y_j^* \geq 3/4 \cdot \sum w_j y_j^*$$

- 终极结论: 混合随机算法成功打破两者各自的瓶颈, 使 MAX-SAT 的近似比提高到了 $3/4$ (0.75)。