

高级算法设计与分析 —— 第7章：概率方法与去随机化

复习精简知识点与全考点梳理手册 (ch7.pdf)

1. 概率方法 (The Probabilistic Method) 核心原理

必考 1.1 存在性引理的底层逻辑

概率方法的核心用于证明某种具有特定数学性质的结构或解**必定存在**（通常用于纯粹的非构造性存在性证明）。

核心逻辑：建立一个适当的概率空间，如果在此空间中，某个事件（即该结构存在）发生的概率 $\Pr[A] > 0$ ，则表明该结构对应的样本点绝对不是空集，从而直接断定该结构一定存在。

高频 1.2 基本计数论证 (Basic Counting Argument) 与拉姆齐数 (Ramsey Number)

- 问题场景**：能否用红蓝两色对完全图 K_n 的边着色，使得不包含任何大小为 k 的单色完全子图？
- 概率构造**：对每条边独立地以 $1/2$ 的概率染红或染蓝。任意大小为 k 的固定子图单色的概率为 $2 \cdot 2^{-(k-1)/2}$ 。
- 应用联合界 (Union Bound)**：图中共有 $\binom{n}{k}$ 个大小为 k 的子图。只要满足：

$$\binom{n}{k} \cdot 2^{1-k} < 1$$

- 则存在至少一种着色方案不包含单色 K_k 。该结论给出了拉姆齐数 $R(k, k) > n$ 的下界证明。

2. 期望论证法 (Expectation Argument)

必考 2.1 期望基本均值性质

设随机变量 X 的数学期望为 $E[X]$ ，则在样本空间中：

- 必然存在至少一个样本点使得 $X \geq E[X]$ 。
- 必然存在至少一个样本点使得 $X \leq E[X]$ 。

利用期望的线性性质 (Linearity of Expectation) 拆解求出整体期望值后，便可断定对应优秀解的存在性。

必考 2.2 MAX-SAT 问题的期望论证 (1/2 近似界)

对于拥有 m 个子句的完全满足问题，每个子句包含至少一个文字。

概率机制： 每个变量独立且随机地以 $1/2$ 的概率设为真。

期望推导： 若第 j 个子句含有 k_j 个文字，其被满足的概率为 $1 - (1/2)^{k_j} \geq 1/2$ 。设 X 为满足的子句总数，则：

$$E[X] = \sum_{j=1}^m \Pr[C_j \text{ 被满足}] \geq m/2$$

结论： 必定存在一种真值赋值，能够使得至少 $m/2$ 个子句同时被满足。

高频 2.3 图的大二分切 (Large Cut in Graphs)

对于任意一个拥有 m 条边的无向图 $G=(V,E)$ ，必然存在一个割 (Cut) (A, B) ，其跨越割的边数至少为 $m/2$ 。

证明核心： 随机将每个顶点以 $1/2$ 的概率划分到集合 A 或 B 。任意一条边其两个端点分别属于不同集合的概率为 $2 \cdot (1/2) \cdot (1/2) = 1/2$ 。由期望线性性质，跨越割的边数期望值为 $m/2$ ，故目标割必然存在。

3. 高阶概率方法：二阶矩与局部引理

重难点 3.1 二阶矩方法 (The Second Moment Method)

二阶矩方法通常用于证明某种结构几乎必然 (With High Probability) 存在。

根据切比雪夫不等式 (Chebyshev's Inequality)，对于非负整值随机变量 X ：

$$\Pr[X = 0] \leq \text{Var}[X] / (E[X])^2$$

在考题中，只要证明当问题规模趋于无穷时，方差相对于期望的平方是一个高阶小量 (即 $\text{Var}[X]/(E[X])^2 \rightarrow 0$)，就能断定 $\Pr[X > 0] \rightarrow 1$ 。

重难点 3.2 Lovász 局部引理 (Lovász Local Lemma, LLL)

当事件之间存在局部的依赖关系时，联合界往往失效。LLL 是一种对抗强局部相关性的终极工具。

定理内容： 设 $A_1, A_2, \dots, A_n$ 为一系列坏事件，每个坏事件发生的概率均满足 $\Pr[A_i] \leq p$ 。若每个事件至多与其余 d 个事件相关联 (不独立)，且满足核心判别式：

$$e \cdot p \cdot (d + 1) \leq 1$$

则所有坏事件均不发生的概率严格大于0 (即 $\Pr[\bigwedge \neg A_i] > 0$)，这意味着好结构必定存在。

4. 去随机化 (Derandomization) 技术

必考 4.1 条件期望方法 (Method of Conditional Expectations)

将一个随机算法转化为确定型多项式时间算法的经典武器。

核心操作： 随机算法需要依次对变量 $x_1, x_2, \dots, x_n$ 进行随机决策。我们不再抛硬币，而是逐个变量选择确定值。在确定 x_1 时，计算并对比两种情况下的条件期望： $E[X | x_1 = 1]$ 和 $E[X | x_1 = 0]$ 。根据均值原理，必定有：

$$\max \{ E[X | x_1=1], E[X | x_1=0] \} \geq E[X]$$

贪心选择使条件期望更大的那个确定值，以此类推。在第 n 步时，条件期望完全收敛到确定性解，且收益必定不低于原随机算法的总体平均期望。

高频 4.2 MAX-SAT 的条件期望去随机化

利用条件期望法将 MAX-SAT 随机算法转换为确定型算法：

- 假设已确定前 $i-1$ 个变量的取值，当前轮需要决定 x_i 。
- 分别高效地计算出 $x_i = 1$ 和 $x_i = 0$ 时满足子句数的条件期望值（此时未决定的变量依然假定以 $1/2$ 概率取值）。
- **决策：** 若 $E[X | x_1, \dots, x_i=1] \geq E[X | x_1, \dots, x_i=0]$ ，则果断令 $x_i = 1$ ；否则令 $x_i = 0$ 。该确定型算法确保找到至少满足 $m/2$ 个子句的解。

重难点 4.3 集合平衡配置问题的去随机化 (悲观限/Pessimistic Estimators)

给定一个大小为 $n \times m$ 的矩阵或全集分配，其随机分配导致的偏差可以用切尔诺夫界 (Chernoff Bound) 进行上界约束。

当条件期望本身极难精确计算时，我们转而寻找一个便于计算的**悲观估计量 (Pessimistic Estimator)** $U(x_1, \dots, x_p)$ ，其作为条件期望的严格上界，并满足单调递减性。通过在每一步极小化该悲观估计量，同样能保证最终生成的确定性解满足误差上界。

高频 4.4 随机电路的去随机化与小空间枚举

如果一个随机算法只需使用 m 个随机比特，且 $m = O(\log n)$ 非常小。

小空间完全枚举技术： 我们不需要真正去抛硬币，而是直接在多项式时间内，穷举所有可能的 $2^m = 2^{O(\log n)} = \text{poly}(n)$ 种随机比特组合。

通过在确定性算法中循环运行这 2^m 次，并采用“多数投票表决 (Majority Vote)”或寻找任意一个输出为 1 的组合，即可将其完美去随机化。